

Métricas de Regressão

1. Introdução ao Problema
2. MSE - OK
3. RMSE - OK
4. MAE - OK
5. Coeficiente de Determinação
6. R^2 Ajustado
7. Implementações

INTRODUÇÃO

MSE

MSE ou erro quadrático médio é uma das métricas preferidas para tarefas de regressão. É simplesmente a média da diferença quadrática entre o valor alvo e o valor previsto pelo modelo de regressão. À medida que eleva ao quadrado as diferenças, ele penaliza até mesmo um pequeno erro que leva a uma superestimação de quão ruim é o modelo. É mais preferido do que outras métricas porque é diferenciável e, portanto, pode ser melhor otimizado

RMSE

RMSE

RMSE é a métrica mais usada para tarefas de regressão e é a raiz quadrada da diferença quadrada média entre o valor de destino e o valor previsto pelo modelo. É mais preferido em alguns casos porque os erros são primeiro ao quadrado antes da média, o que representa uma grande penalidade para erros grandes. Isso implica que o RMSE é útil quando grandes erros são indesejados

MAE

MAE é a diferença absoluta entre o valor alvo e o valor previsto pelo modelo. O MAE é mais robusto para outliers e não penaliza os erros tanto quanto o mse. MAE é uma pontuação linear, o que significa que todas as diferenças individuais são ponderadas igualmente. Não é adequado para aplicações em que você deseja prestar mais atenção aos valores discrepantes.

R²

Coeficiente de determinação ou R^2 é outra métrica usada para avaliar o desempenho de um modelo de regressão. A métrica nos ajuda a comparar nosso modelo atual com uma linha de base constante e nos diz o quanto nosso modelo é melhor. A linha de base constante é escolhida tomando a média dos dados e desenhando uma linha na média. R^2 é uma pontuação sem escala que implica que não importa se os valores são muito grandes ou muito pequenos, o R^2 será sempre menor ou igual a 1.

R² AJUSTADO

R^2 ajustado representa o mesmo significado que R^2 , mas é uma melhoria dele. O R^2 sofre do problema de que as pontuações melhoram em termos crescentes, embora o modelo não esteja melhorando, o que pode confundir o pesquisador. O R^2 ajustado é sempre menor do que o R^2 , pois se ajusta para os preditores crescentes e só mostra melhora se houver uma melhora real

IMPLEMENTACAO

1. Criando modelo

É importante ter em mente que, neste exemplo, estamos usando dados arbitrários. Podemos fazer este exercício com qualquer conjunto de dados. X é uma matriz de inteiros de 0–9. Y é uma matriz dos primeiros 10 dígitos da sequência de Fibonacci. Depois de traçar os pontos de dados, ajustaremos nossa linha de regressão de mínimos quadrados comum.

Esta linha parece se ajustar relativamente bem. Os pontos azuis não estão muito longe da linha de regressão. Quanto mais próximos os pontos estão da linha, menor é a nossa variância. Quanto menor for a variância, melhor será o nosso modelo!

2. Linha média

A seguir, colocaremos outra linha em nossos dados. Se teoricamente tivéssemos apenas os dados Y (e nenhum X), o melhor modelo preditivo que seríamos capazes de fazer seria adivinhar a média de Y todas as vezes. Esta é uma etapa fundamental no cálculo de nosso r -quadrado, como você verá em um minuto.

3. Diferença entre os dados e o modelo linear

Se medirmos a diferença entre cada ponto de dados e a linha de regressão linear, elevar ao quadrado cada diferença e totalizá-los, obteremos a variância que existe dentro do modelo de regressão.

4. Diferença entre os dados e a média

Se medirmos a diferença entre cada ponto de dados e a linha horizontal, elevarmos ao quadrado cada diferença e totalizá-los, obteremos a variância total que existe apenas no conjunto de dados Y. Lembre-se, este é o modelo que usaríamos independentemente da existência de nossos dados X